第3节.搜索引擎性能评价

刘奕群 清华大学计算机系 智能技术与系统国家重点实验室 2015年3月17日



引言.搜索引擎性能评价的目的

谷歌网站搜索速度提升 雅虎末路

雅虎搜索引擎重大升级 自称比Google功能更全

张忆芬评价: 百度谷歌都不如雅虎搜索?

据 升 観化が 网站: 明显 不在#8 月4 第号け 称自己は 了约2 所添: 中处于 的索 环境中的 引擎 经非在榜 站在 网站 Goog

Word 20

雅虎称其数据库超谷歌为全球最大

谷歌每天处理2万TB数据 与雅虎微软相比优势明显

张朝阳: 搜狗3.0已超百度、雅虎

【来源:中国证券网.上海证券报】

口本报记者 张韬

昨天记者从搜狐获悉,搜狗3.0版本将于2007年1月1日正式上线。搜狐公司董事局主席兼首席执行官张朝阳对搜狗充满信心,甚至放言:"3.0是换代产品,已经在技术上超过了百度和雅虎!"

2007年正式上线的搜狗3.0采用新的技术架构———自主研发的服务器集群并行抓取技术,中文网站收录量从2006年8月的50亿猛增到100亿,已覆盖中文网页数据量的50%以上,每天的更新速度达到5亿网页。搜狗3.0在搜索结果的排名上采用搜狗网页评级体系,不仅考察网

页之间的链接关系,同时考察了链接质量、链接之间的相关性等特性,网页评级越高,该网页在搜

前的承洋提出了还有书的支线

引言.搜索引擎性能评价的目的

- •对搜索引擎用户而言:
 - 挑选最有利于获取信息的渠道
- •对搜索引擎广告商而言:
 - 挑选最有效的广告投放手段
- •对搜索技术研究人员而言:
 - •评价在信息检索系统的研发中一直 处于核心的地位,以致于算法与其 效果评价方式是合二为一的 (Saracevic, SIGIR 1995)



引言.搜索引擎性能评价的目的

- •对于搜索引擎服务提供者
 - 从较差查询样例中学习

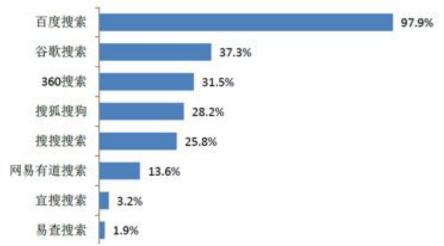


本节概要

- •搜索引擎性能评价流程
- •用于性能评价的语料库采集
- •用于性能评价的查询样例集合构建
- •用于性能评价的结果相关性标注
- •搜索性能评价指标设计



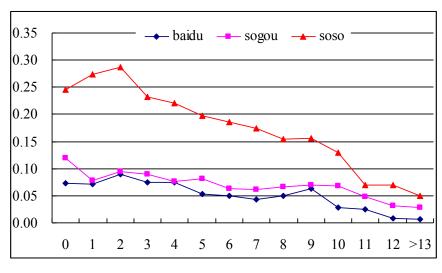
- •1.1 搜索引擎性能评价的对象
 - •作为网络服务供应商的属性

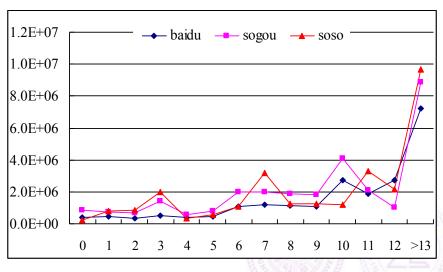


Core Search Entity	Explicit Core Search Share (%)		
Core search Entity	Nov-13	Dec-13	Point Change
Total Explicit Core Search	100.0%	100.0%	N/A
Google Sites	66.7%	67.3%	0.6
Microsoft Sites	18.1%	18.2%	0,1
Yahoo Sites	11.2%	10.8%	-0.4
Ask Network	2.6%	2.5%	-0.1
AOL, Inc.	1.4%	1.3%	-0.1

- •作为网络信息检索工具的属性
 - •传统的信息检索系统评价方式如何应用于搜索引擎?如何充分考虑网络数据环境与用户群体的影响?

- •1.1 搜索引擎性能评价的对象
 - •搜索引擎系统运行效率 (Effciency)
 - 用户需求是否得到了很快的响应?
 - 为满足用户需求耗费了多大规模的硬件资源?

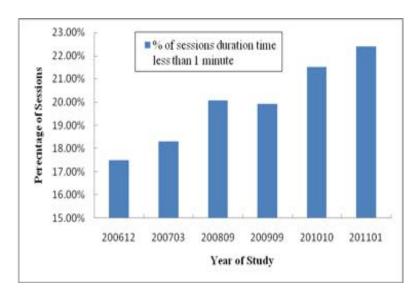


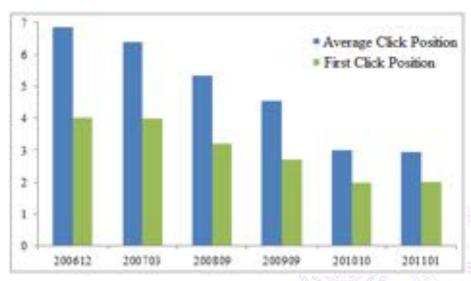


反馈时间

结果条目数

- •1.1 搜索引擎性能评价的对象
 - •搜索引擎系统运行效果 (Effectiveness)
 - •是否满足了用户的信息需求?
 - 用户获取信息所耗费的时间成本如何?



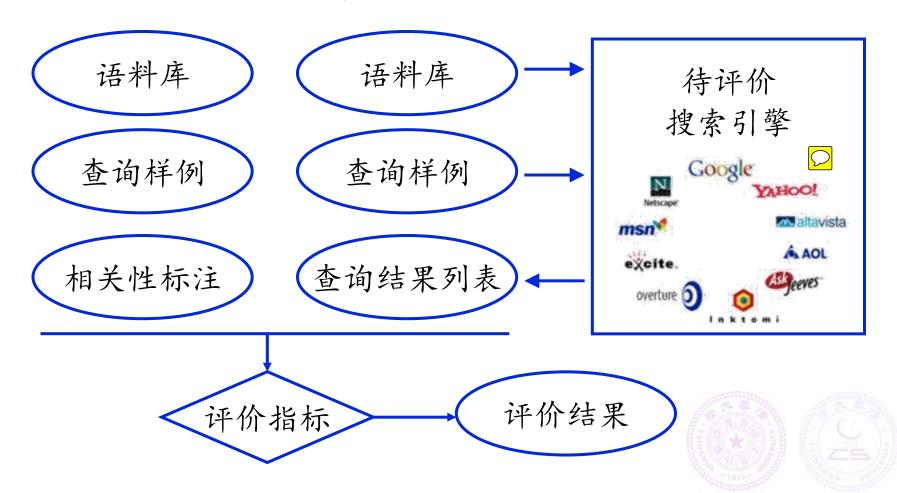


- •1.2 搜索引擎性能评价的Cranfield体系
 - •性能评价的"黑箱"方式
 - •给定标准输入情况下,系统输出与标准输出之间的差异
 - Cranfield评价体系
 - Cleverdon等人于1960年前后在英国Cranfield大学提出
 - 奠定了"评价"在信息检索研究中的核心地位





•1.2 搜索引擎性能评价的Cranfield体系



- •1.2 搜索引擎性能评价的Cranfield体系
 - Cranfield评价体系的实践应用
 - 文本信息检索会议(Text REtrieval Conference, TREC)
 - 1992年开始,由NIST和DARPA共同主办;CMU, Umass, UIUC, IBM, MSRA/C, ...; THU, PKU, NUS, TOKYO, ...
 - 国立信息技术研究所信息检索评测(NII Testbeds and Community for Information access Research)
 - 1997年开始,由日本NII主办;强调东方语言评测任务。
 - 其他专题评测: CLEF, FIRE, SEWM, ...

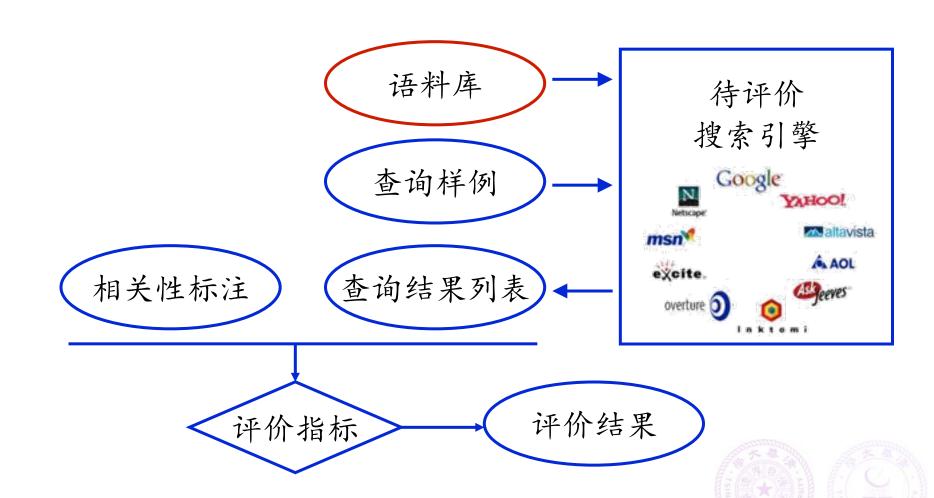


- •1.2 搜索引擎性能评价的Cranfield体系
 - Cranfield体系的优势:
 - 复用性: 一次标注, 多次使用
 - ·如何用Cranfield评价体系进行检索效果评价
 - •如何采集评价语料
 - •如何构建查询样例集
 - •如何进行相关性标注
 - •如何设计评价指标

面临哪些技术问题? 施行的方法是什么?



2. 语料库采集



2. 语料库采集

- •对于信息检索系统
 - •提供固定的语料库集合
 - •集合规模适当: VLC2案例
 - •数据质量可靠: ClueWeb案例
- •对于商业搜索引擎
 - 不提供固定的语料库集合
 - •评价数据抓取子系统性能
 - •索引量战争,暗网抓取,...





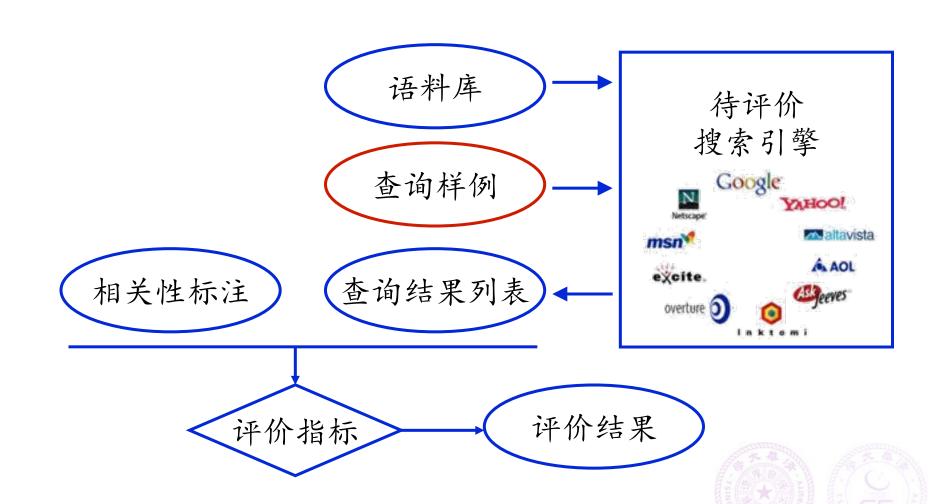
2. 语料库采集

•案例: 360与百度关于数据抓取的官司





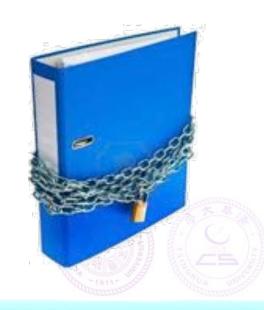
http://baike.baidu.com/robots.txt



- •用户查询规模庞大
 - ComScore: More than 18.2 billion explicit core searches were conducted per month in U.S.
 - · 艾瑞咨询: 2011年第三季度中国网页搜索请求量即 达到775.1亿次
- •核心问题:如何采样
 - 真实性: 反映用户实际需求
 - •精确性:减少相关性标注困难
 - •全面性:综合评价各方面性能



- •3.1 查询采样的真实性
 - •来源:用户查询行为日志
 - TREC 评测: Bing, Yahoo!
 - NTCIR评测: Bing, 搜狗
 - SEWM评测:天网搜索
 - •日志收集的隐私保护: AOL案例
 - •公开数据资源
 - 查询排行: 百度风云榜, 每日热搜词
 - 搜索日志: SogouQ, WSCD, Yandex



•3.2 查询样例的精确性

<top>

chance Number: 751.

<title> Scrabble Players

<desc> Description:

Give information on Scrabble players, when and where Scrabble is played, and how popular it has been.

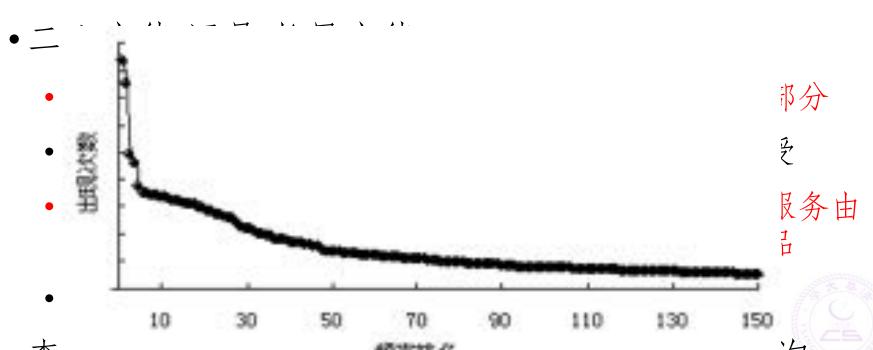
cmarry Marrativet

Give information on the social aspects of the game Scrabble. Scrabble players may be named or described as a group. Both real and fictional players are relevant. Mention of a scheduled Scrabble game is relevant. Scrabble's popularity is relevant. An account of a particular game is relevant. Descriptions of variants on the Scrabble game are not relevant. Use of Scrabble tiles for other purposes are not relevant. Scrabble software is not relevant unless there is mention of its users. Titles of Scrabble-related books (dictionaries, glossaries, rulebooks) are not relevant.



- •3.3 查询采样的全面性
 - •用少量的查询样例代表大多数需求类别
 - 通常考虑的采样依据有哪些?
 - 查询的内容类别
 - •用户查询内容分类体系: KDDCup 2005
 - •网络内容分类体系: Yahoo! 网页目录
 - 查询的热门程度: 查询频度分布
 - 查询的需求类型: 用户需求分布

- •3.3.1 搜索引擎用户查询频度分布规律
 - •实际分布数据(搜狗搜索,2008年6月)
 - 总数: 1500万; 最热门的1万个查询覆盖56%的用户需求



- •3.3.2 搜索引擎用户信息需求分布
 - •查询:沟通繁杂的数据环境与丰富的用户意图
 - 查询信息需求(information need)
 - 用户查询背后的不同类型的信息获取需要
 - 决定了用户使用搜索引擎的满意程度
 - 直接反映在用户与搜索引擎的交互行为上
 - •案例: 学堂在线主页/NBA在线观看/什么是大数据
 - •案例: 魔兽争霸

3.3.2 搜索引擎用户信息需求分布

•案例: 魔兽争霸

•用户1: 到达某些特定站点

点击次序	被点击结 果的排序	URL	
1	9	war3xp.xiyou.net/	
		结束查询	

点击次序	被点击结果的排序	URL
1	- 7	www.aomeisoft.com/war3/wc3/
结束查询————————————————————————————————————		

3.3.2 搜索引擎用户信息需求分布

•案例: 魔兽争霸

•用户2:游戏下载

		The same of the sa
点击次序	被点击结果的排序	URL
1	4	www.it.com.cn/f/hotweb/053/17/88017.htm
2	3	war3.ogame.net/
3	2	www.gamedge.net/
4		war3.cga.com.cn/
5	5	games.tom.com/zhuanti/war3/
6	7	www.aomeisoft.com/war3/wc3/
7	10	war3xp.xiyou.net/
8	魔兽争霸3下载	ewnf.com/1/war.htm

3.3.2 搜索引擎用户信息需求分布

•案例: 魔兽争霸

•用户3: 获取资讯

点击次序	被点击结果的排序	URL
1	1	war3.cga.com.cn/
2	4	www.it.com.cn/f/hotweb/053/17/88017.htm
3	3	war3.ogame.net/
4	6	www.pcgames.com.cn/fight/warcraft/

- •3.3.2 搜索引擎用户信息需求分布
 - 查询的信息需求分类体系(Broder, 2003)
 - •导航类 (Navigational, Known item search)
 - 查找某个已知存在的页面/资源
 - •信息类 (Informational, Key resource finding)
 - 查找与某个主题相关的关键信息资源
 - 事务类 (Transactional, Task-oriented search)
 - 查找与完成某个特定任务相关的资源



- •3.3.2 搜索引擎用户信息需求分布
 - •导航类查询案例
 - 主页查找(Homepage Finding)
 - 百度 www.baidu.com
 - 北京大学 www.pku.edu.cn
 - 其他资源查找(Named-page Finding)
 - 清华大学2014年研究生招生简章
 - 护照申请表
 - 2012年高考数学试卷



- •3.3.2 搜索引擎用户信息需求分布
 - •信息类查询案例
 - 获取相关信息,没有确定的查询目标
 - 香港股市: hk.finance.yahoo.com; cn.biz.yahoo.com/ stock/hk.html
 - 往往需要不止一个结果
 - 麦迪: www.t-mac.cn; tieba.baidu.com/f?kw=麦迪
 - 在查找的过程中逐渐深化认识
 - 关节肿胀 => 痛风 => 嘌呤



- •3.3.2 搜索引擎用户信息需求分布
 - •事务类查询案例
 - •与完成特定任务相关,没有确定的查询目标
 - Ultraedit 下载: www.onlinedown.net/soft/7752.htm; www.skycn.com/soft/22314.html
 - 往往一个结果就可以满足需求
 - 星星大结局: www.iqiyi.com/v_19rrh6qq.html
 - 垂直搜索引擎服务的对象



•3.3.2 搜索引擎用户信息需求分布



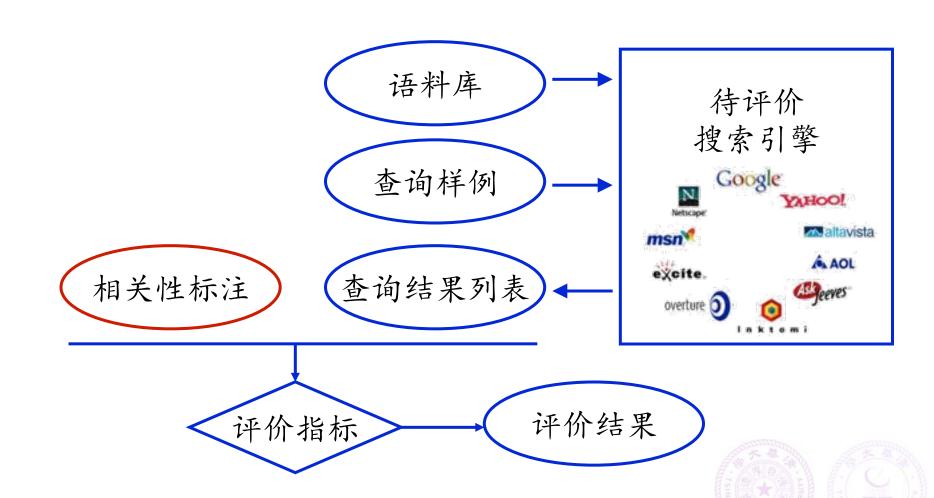
- •信息需求分布估计
 - Broder: 20%/50%/30% (导航/信息/事务)
 - Rose: 14.7%/60.9%/24.4% (导航/信息/事务)
 - •对2008年6月某搜索引擎的抽样标注:导航类约占30.6%,信息/事务类约占69.4%
- 中英文用户行为习惯差异
- •采样方法差异
 - •信息需求 v.s. 热门程度



- •查询热门程度
 - 充分重视热门查询的作用
 - 必须有适当的冷门查询代表
- •查询信息需求
 - •包含导航类、信息类、事务类三种不同类型的查询信息需求
 - •三种信息需求类别比例约为: 2:5:3







- •4.1 结果相关性标注的标准
 - •需要注意的问题:内容相关 ≠ 关键资源

序号	结果标题	结果URL
1	欢迎光临清华大学	www.tsinghua.edu.cn
2	清华大学_百度百科	baike.baidu.com/view/1563.htm
3	清华大学_新浪院校库	kaoshi.edu.sina.com.cn/college/c/10003.shtml
4	清华大学图书馆	www.lib.tsinghua.edu.cn
5	清华大学地图	map.baidu.com/#word=%c7%e5%bb%aa%b4%f3%d1%a7
6	國立清華大學	www.nthu.edu.tw
7	清华阳光	www.thsolar.com
8	清华美术学院	ad.tsinghua.edu.cn
9	清华大学公共管理学院	www.sppm.tsinghua.edu.cn
10	清华大学的相关新闻	news.baidu.com/ns?word=%c7%e5%bb%aa%b4%f3%d1%a7

- •4.1 结果相关性标注的标准
 - •对相关性结果的共性要求
 - 结果所提供的信息应当时新、真实可靠
 - 结果的标题和摘要应当方便阅读并有效引导用户阅读
 - •以信息需求类别为指导



查询信息 需求类别	相关结果评价标准	
导航类	结果即为用户的检索目标	
信息类	结果能够为用户信息需求所涉及的主题 提供权威性的信息和引导	
事务类	结果能够协助用户顺利完成所需任务	

- •4.1 结果相关性标注的标准
 - •不同标注人员的判定标准存在差异
 - TREC 2008案例: 在可能相关的200个文档中, 仅有85个意见一致

	标注人员B: 相关	标注人员B: 无关
标注人员A: 相关	85	51
标注人员A: 无关	64	567

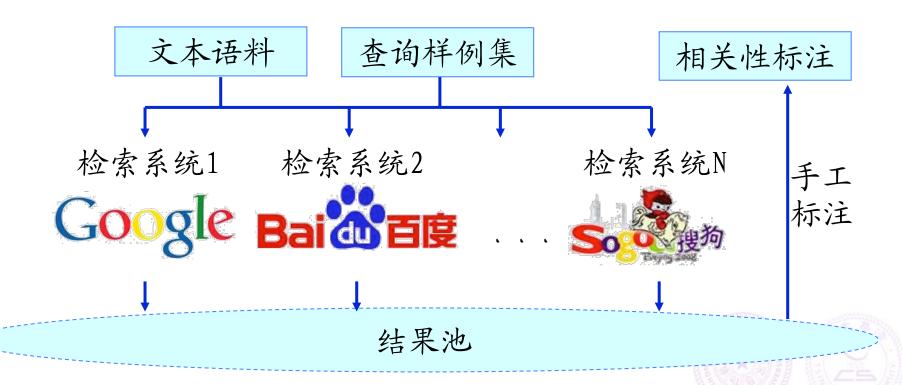
- •解决思路
 - 查询样例集合构建时添加精确需求描述
 - •专业标注人员 v.s. Crowd sourcing

- •4.2 结果相关性标注的人力成本
 - •TREC对人力成本的估计
 - 一个规模为800万的文档集合;针对1个查询主题的相关性评判;需要耗费1名标注人员9个月的工作时间
 - •如何提高相关性标注集合构建的效率?
 - Pooling方法:保证评价结果可靠性的基础上减少工作量
 - 假设:没有被任何一个系统 检索出的答案对于评价检索 系统的性能没有意义

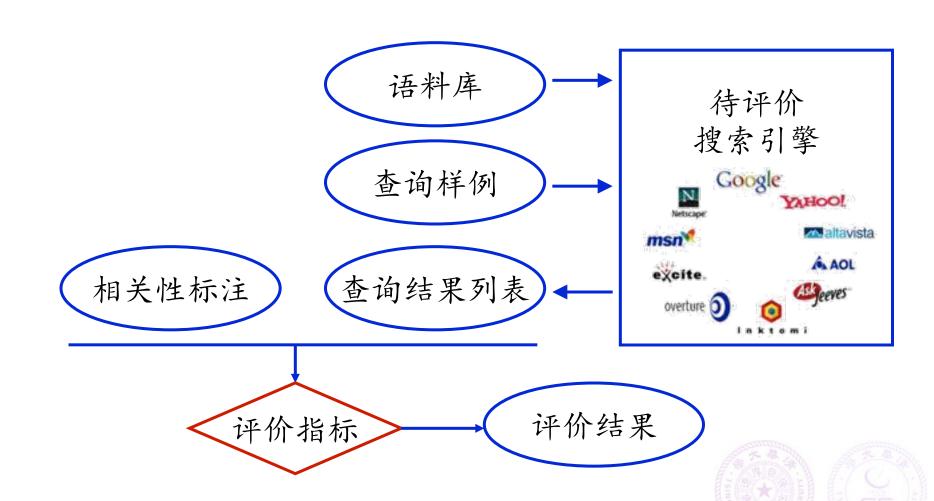


4. 结果相关性标注

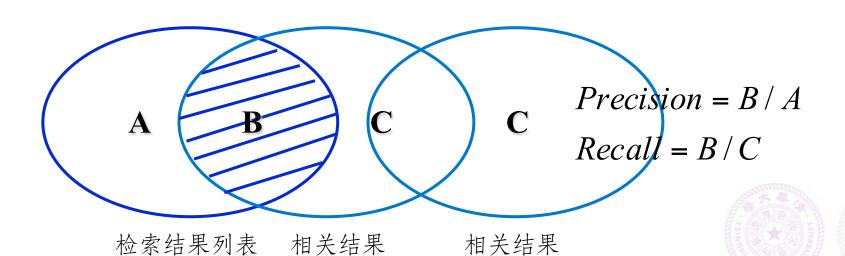
- •4.2 结果相关性标注的人力成本
 - •结果池过滤方法(Pooling)



5. 评价指标设计



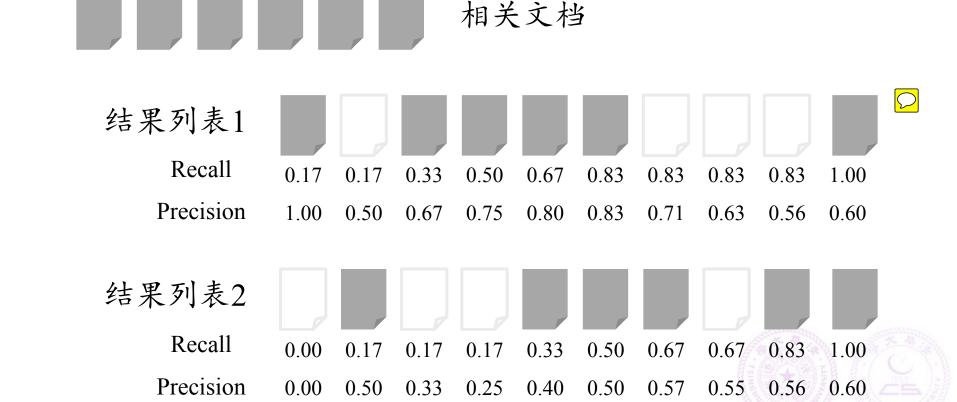
- •准确率/召回率
 - •Kent等人1955年提出了关于Precision和Recall的概念
 - •准确率(Precision): 找到的是否准确
 - 召回率(Recall): 找到的是否全面



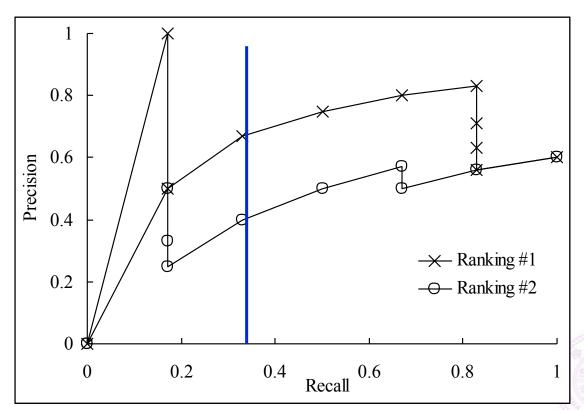
- •准确率/召回率
 - •垃圾电子邮件识别
 - 准确率: 有多少识别出的信件真的是垃圾信件
 - 召回率: 是否所有的垃圾邮件都被识别出了
 - •疾病的医学诊断
 - 准确率: 诊断患病的病人有多少真的患病
 - 召回率:有多大比例的患病的病人被诊断出
 - •信息检索强调"序列"的关系
 - 在结果序列中计算准确率与召回率



•检索结果序列中准确率/召回率的计算



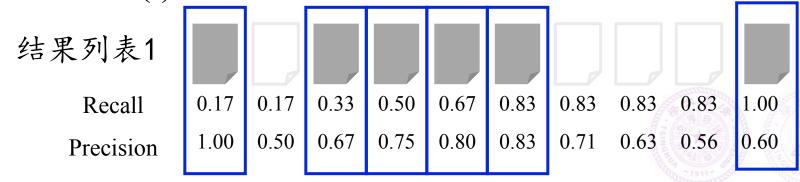
- •准确率/召回率曲线
 - •比较不同系统之间的性能差异



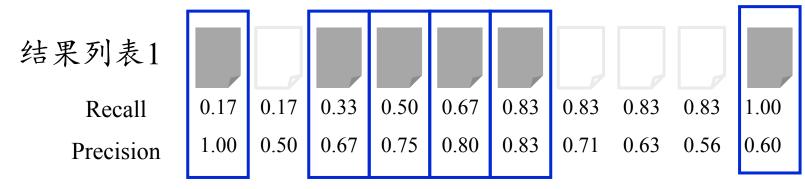
- •综合考虑准确率与召回率的指标
 - 平均准确率(Average Precision, AP)

$$AP = \frac{1}{N} \sum_{i=1}^{N} Precision(i)$$

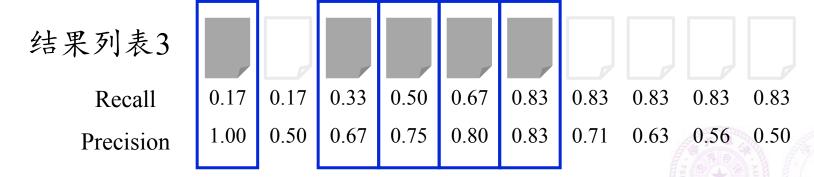
- ·N为已知相关结果的总数
- Precision(i)为系统找到第i个答案时的Precision



•平均准确率(AP)的计算



$$AP = (1.00 + 0.67 + 0.75 + 0.80 + 0.83 + 0.60)/6 = 0.78$$



$$AP = (1.00 + 0.67 + 0.75 + 0.80 + 0.83)/6 = 0.68$$

- •信息检索评价方法如何应用于搜索引擎?
 - •搜索引擎用户行为的特殊性
 - 约85%的用户只翻看搜索引擎返回的前10个结果。
 - 大部分用户甚至不会滚动网页查看其他结果
 - •搜索引擎用户信息需求的差异性
 - •导航类信息需求的用户仅关注特定检索目标
 - •信息类信息需求的用户关注全面而权威的信息
 - •事务类信息需求的用户关注自己的任务是否可以顺利完成。

•5.2.1 首位相关结果倒数(Reciprocal Rank)

对名前结有排靠的果利

•适用于导航类型的查询信息需求(用户在找到搜索目标前需要浏览多少结果?)

- •5.2.2 前N位准确率(Precision@N)
 - •N=10, 20: 第一页结果中的准确程度
 - •N=5: 用户不滚动屏幕时结果的准确程度

 结果列表1

 结果列表2

 结果列表3

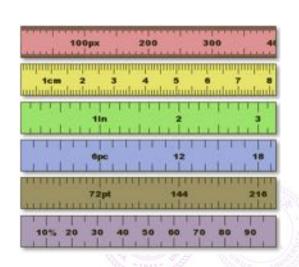
•适用于信息类型的查询信息需求(结果列表中多大比例信息能够满足用户需求?)

- •5.2.3 前N位成功率(Success@N)
 - •N=10, 20: 第一页中是否有满足用户需求的结果
 - •N=5: 不滚动屏幕时是否有满足用户需求的结果
 - •N=∞:搜索引擎是否有满足用户需求的结果



•适用于事务类型的查询信息需求(用户是否能够利用给出的结果完成自己所关注的事务?)

- •5.2.4 其他常用评价指标
 - NDCG@N:
 - Normalized Discounted Cumulative Gain
 - 对结果进行多级相关性标注时适用
 - ERR: Expected Reciprocal Rank
 - Supported by Yahoo! and Google
 - 可以获取用户行为数据时适用
 - B-pref: Binary preference
 - 相关性标注不完整时适用



6. 总结与展望

- •Cranfield评价体系可能的弊端
 - •以"查询一结果"的相关性标注为核心
 - •信息检索系统用户:逐一认真阅读结果文档
 - •搜索引擎用户:尽快获得信息,不一定访问结果网页
 - 与用户的搜索引擎使用行为不完全匹配
 - 通过摘要直接获得信息
 - 通过垂直搜索服务获得信息
 - 通过知识图谱/框计算结果直接获得信息



6. 总结与展望

- Beyond Cranfield methodology
 - User preference test
 - Interleaving test

www napavalley org

搜索内容为程序员 音询意图为 程序员 网站
 程序员介绍
 程序员 职业
 程序员 课程
 程序员招聘 **Presented Ranking** 招聘PHP程序员/软件工程师-北京无限新空信息技术 四川在线人才频道 Napa Valley - The authority for lodging (2008/04/15) 来源 四川在线人才频過 对于程序员的学师、程序员一般要求本科毕业、有些公司对于自学的程序员、如果有工作经验的选不受限制、通 注册企业注册您现在的位置: 藏页>职位搜索>北京无限新空信息技术有限公司 >PHP程序员/软件工程师公司第分所有职位PHP程序员/软件工程师宏有时间: www.napavallev.com 2008/08/11 浏览: 3190次 http://www.cnithr.com/personal/user_show_job.php?id=476290 Maratho 2. Napa Country, California - Wikipedia vmarathor 程序员单身之谜 绘数程序员"六宗罪" [软件新闻行 en.wikipedia.org/wiki/Napa Valley 招聘对日开发java程序员-世纪新动信息技术(北京. 于业新闻程序员单身之谜细数程序员"六宗事"(软件新闻行业新闻)CSDN2007-11 注册企业注册您现在的位置: 首页>职位搜索>世纪新动信息技术(北京) 有限 168:16:00 文/WinberLink(**). Napa: The Story of an American Eden... 公司>对日开发java程序员公司第分所有职位对日开发java程序员发布时间:200 可算是把程序员的角色 tp://it.yg.sx.cninfo.net/Fedu/0711/16/508856.htm http://www.cnithr.com/personal/user_show_job.php?id=365322 books.google.co.uk/books?isbn=... Napa Valley Wineries - Plan your wine... SCJP--Sun认证Java程序员考试专题[中国. 首 西|疫讯中心| IT培訓||活程教育||技术者語||複 索 |解价||论坛头条 考勤 视点 考栏 唇悬纖 访咨 调查 人物 图片 行业规章 海外论坛 www.napavalley.com/wineries 慧纸 剧投天下 附经程序员高额之路现在随便登结一个人才网站。都可以看到 网络产品/学习下载/在线制试/在线实验们社区 招聘软件人才的信息调天盖地。但是不同企业 Napa Valley Hotels - Bed and Breakfast... http://tech.tom.com/zhuanti/ccidedu_tom/rkzx/cxygxzl.htm. http://www.chinatlab.com/www/special/scip.asp www.napalinks.com www.pudn.com - 最大的源码下载中文网 6. Napa Balley College 留字[常厉横板[文化历史]祖图推荐]使未问吧[学习俱乐部往日头条在线实验职场 程序员5名。企业信息系统设计与开[成正软件]高级程序员2名。程序设计|北京计算 、微軟面试大学明整個級女声藝術下數數傳籌維育同由入门学习因地视觉描述。 机图书]文档管理员20名 编写计算机书题[惠州华臣 net]文档管理员1名.美工[err www.napavalley.edu/homex.asp 宴 软件资格和水平考试各地咨询地址 程序设计(初级程序员级 beddedsoftware]程序员 http://www.enet.com.cn/edu/hot/kaoshi/ http://www.programsaion.com/default.asp NapaValley.org

左边好+1

左边好+2

右边好+4

右边好+2

完成一點,再接再厉

实验1:搜索引擎性能评价

- 实验步骤
 - 1. 自由分组,2人一组
 - 2. 构建查询样例集合:利用网络资源 (http://top.baidu.com/; http://top.sogou.com/等) 和个人使用经验构建查询样例集合,查询样例集合需覆盖不同查询热门程度(冷门/热门)和各种类型的用户查询需求(导航类/信息类/事务类),样例集合的规模为10个查询,各类比例为2:5:3,并根据个人经验,撰写每个查询样例的信息需求内容。

实验1:搜索引擎性能评价

- 实验步骤
 - 3. 构建Pooling:学生根据其构建的查询样例集合, 抓取常用的三个中文搜索引擎(百度、360搜、搜 狗)对这部分查询词的查询结果,每个搜索引擎 抓取查询结果的前十位结果,并利用这些结果构 建Pooling。
 - 4. 构建相关性标注集合:根据步骤2中撰写好的信息需求,对Pooling里的结果进行标注,标注为"答案"和"非答案"两类即可。

实验1:搜索引擎性能评价

- 实验步骤
 - 5. 根据标注结果,依据MAP,P@10,MRR等评价 指标对各个搜索引擎的查询性能进行评价,并对 搜索引擎满足不同信息需求的情况加以比较,每 人各自撰写实验报告。
 - 6. 扩展内容:可以尝试对搜索引擎处理非中文查询、有错别字查询等情况的不同策略进行分析、比较。
 - 7. 实验截止日期: 3月25日23:00,提交实验报告、 查询样例集合、Pooling集合和相关性标注集合

通知

- •下节课程:搜索引擎的历史变迁与未来发展
- •授课人:

百度公司副总裁,国际计算语言学协会主席 王海峰博士

- •地点: 6A017教室
- •时间: 24日下午1:30-3:00

